Доклад по предмету
“Введение в искусственный интеллект”

Санкт-Петербург 2025

Выполнил студент 22б.08
Углов Владислав

1. Постановка задачи

Классификация архитектурных сооружений на 25 классов является задачей компьютерного зрения, направленной на автоматическую классификацию различных типов зданий

Данная область имеет прикладное значение в сферах городского планирования, культурного наследия, туристических приложений и систем мониторинга состояния зданий.

Целью данного проекта является сравнение эффективности двух предобученных моделей — ResNet50 и MobileNetV3 — в задаче классификации архитектурных сооружений.

Отдельное внимание уделяется методам аугментации данных, подбору оптимального шага обучения и стратегии обучения с циклическим изменением скорости обучения (One Cycle Learning Rate).

2. Описание используемой нейронной сети

2.1. ResNet50

Предобученная на наборе ImageNet. ResNet50 отличается наличием остаточных связей (residual connections), что позволяет строить глубокие сети без проблем затухания градиента.

Для адаптации к задаче классификации архитектурных сооружений выполнены следующие шаги:

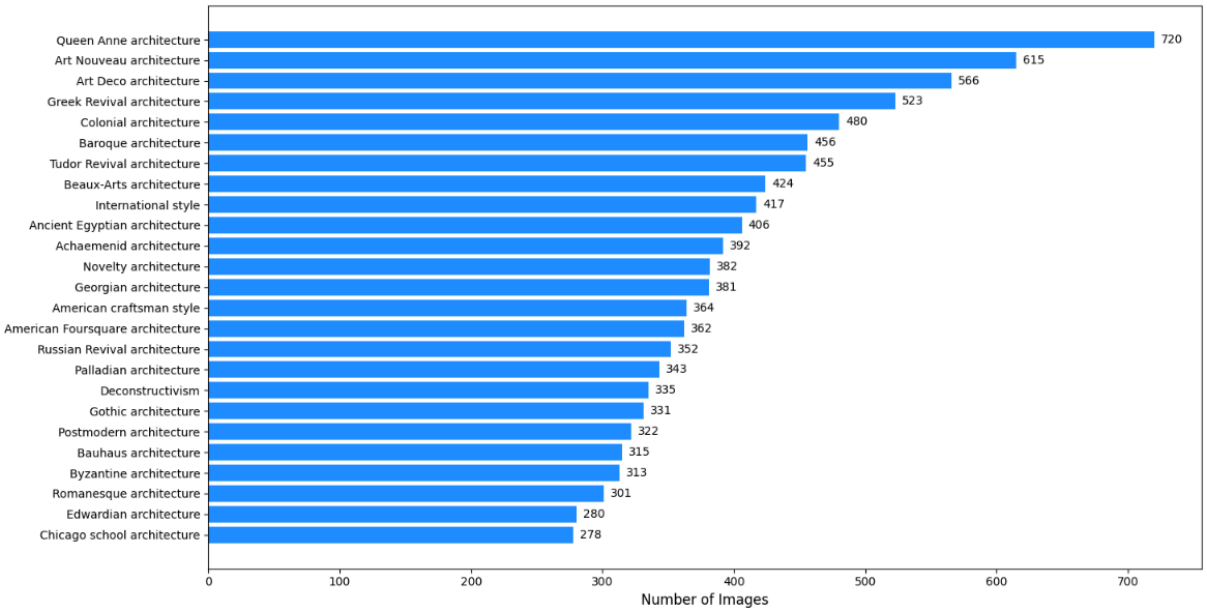
1. Заморозка весов всех слоев, кроме последнего блока. Это обеспечивает сохранение общих признаков, извлеченных на ImageNet.

2. Замена стандартного классификационного слоя (fully connected) на новый полносвязный слой с выходом, соответствующим количеству классов архитектурных сооружений в датасете.
3. Добавление l2 регуляризации для предотвращения переобучения путем штрафа модели за большие веса

Такая структура позволяет эффективно использовать предварительно накопленные знания модели и адаптировать её к узкоспециализированному набору данных.

3. Аугментация данных

В исходном датасете наблюдалось неравномерное распределение изображений по классам, что может приводить к смещению модели в сторону более представленных классов. Для борьбы с этим применены методы аугментации:



- **Горизонтальный флип**: разворот изображений по горизонтали.

- **Поворот (до ±10°)**: случайные повороты, сохраняющие геометрию здания.

- **Масштабирование (до 1.1×)**: увеличение и уменьшение масштаба для устойчивости к разным расстояниям до объекта.

- **Локальные нелинейные искажения (warp)**: случайные деформации для повышения робастности.

- **Изменение яркости и контраста**: для адаптации к разным условиям освещения.

4. Обучение.

4.1. Метод нахождения оптимального шага обучения

Подбор шага обучения является ключевым этапом в оптимизации процесса обучения. Для определения оптимального значения был использован метод lr_find() реализованный в FastAI. Алгоритм заключается в следующем:

1. Инициализация обучения с экспоненциальным увеличением шага от очень малого до большого в течение короткого числа итераций

2. Наблюдение кривой изменения функции потерь от шага обучения.

3. Выбор значения шага обучения в области, где функция потерь начинает стремительно снижаться, но до точки, где она начинает расти.

Метод позволяет автоматически получить приближенное оптимальное значение LR без ручной подгонки и существенно ускоряет настройку модели.

4.2. Фичи обучения

В качестве основной функции обучения использовался метод One Cycle Learning Rate, реализованный в FastAi.

Основные преимущества этого метода:

- **Адаптивное изменение шага обучения**: LR увеличивается до максимального значения, а затем плавно уменьшается.

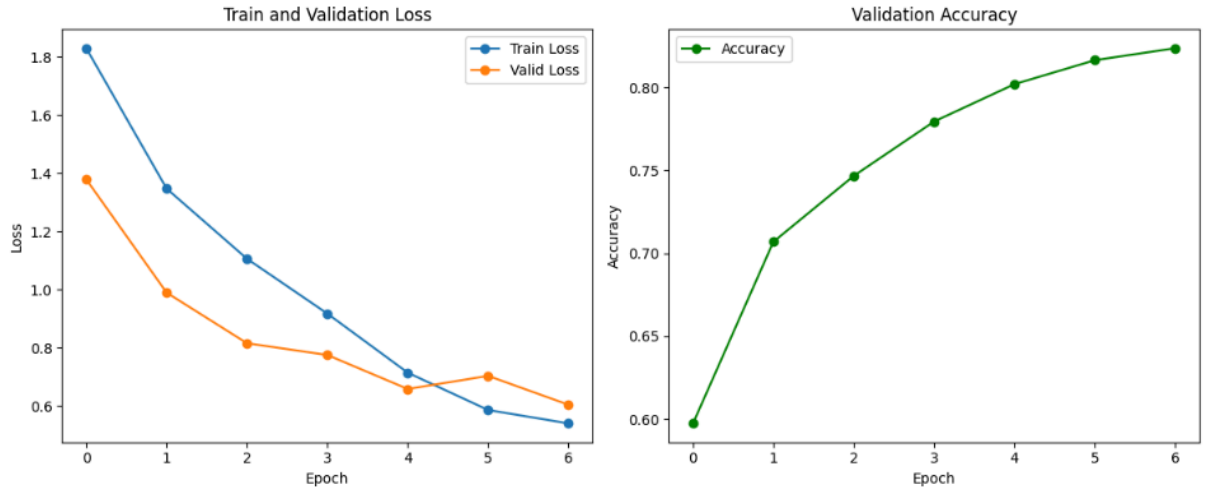
- **Стабилизация процесса обучения**: LR изменяется после каждого батча, что позволяет не застревать в локальных экстремумах

Была добавлена l2 регуляризация со значение для штрафа модели за большие веса. Параметр лямбда равен 1e-1.

4.3. Обучение модели ResNet50

Обучение проводилось в течение малого числа эпох - 7. Максимальный LR получился 2e-3.

В результате обучения достигнута точность на валидационном наборе 83.4%, что свидетельствует о хорошей способности модели к обобщению и правильной настройке гиперпараметров.



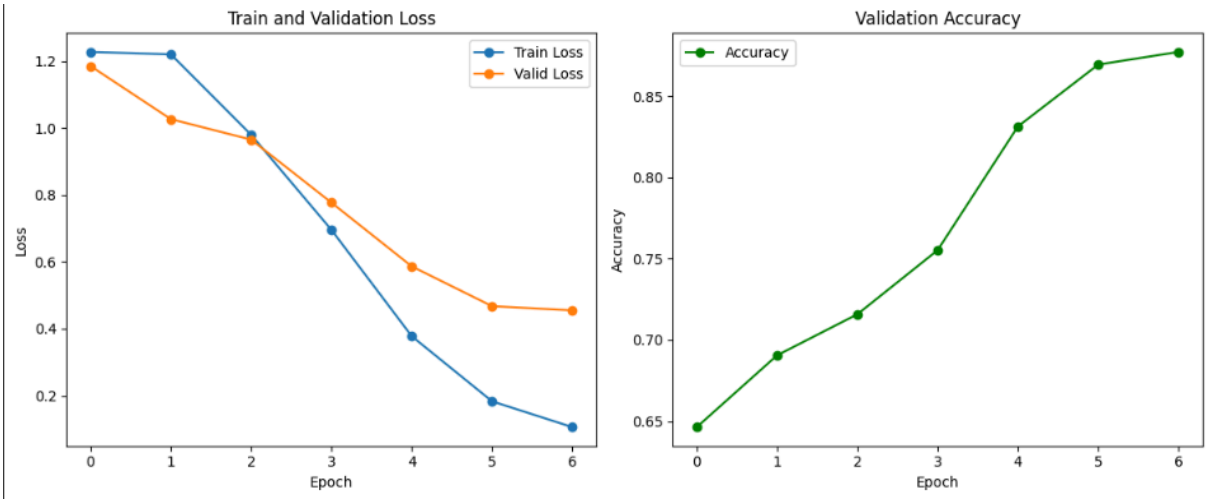
epoch	train_loss	valid_loss	accuracy	time
0	1.829929	1.379282	0.597500	04:03
1	1.347442	0.990010	0.706944	04:04
2	1.106360	0.816204	0.746667	04:02
3	0.917942	0.775768	0.779444	04:00
4	0.714966	0.659043	0.801944	04:01
5	0.586724	0.704071	0.816389	04:01
6	0.540728	0.604857	0.823611	04:04

4.3 Обучение модели MobileNetV2

Для сравнения эффективности архитектур аналогичные эксперименты были проведены с моделью MobileNetV2, также предварительно обученной на ImageNet.

Обучение проводилось в течение малого числа эпох - 7.

Максимальный LR получился 1e-3



Результаты показали точность на валидации 87.7%, что чуть выше, чем у ResNet50, но при этом одна эпоха обучения на 25% быстрее, чем у ResNet50.

epoch	train_loss	valid_loss	accuracy	time
0	1.227458	1.185184	0.646389	03:17
1	1.220281	1.026519	0.690556	03:11
2	0.979624	0.965330	0.715833	03:08
3	0.695436	0.776930	0.755278	03:08
4	0.377619	0.586430	0.831389	03:12
5	0.183145	0.467566	0.869444	03:16
6	0.105975	0.454991	0.877222	03:13

8. Выводы

В ходе эксперимента MobileNetV3 показала лучшую точность (87.8%) по сравнению с ResNet50 (85%), при этом MobileNetV2 выигрывает в скорости и компактности.
Модель ResNet50 имеет 25 миллионов параметров. MobileNetV2 имеет 5 миллионов параметров.

Таким образом, проект продемонстрировал ряд подходов в глубоком обучении: от аугментации до подбора шага. Также показал важность выбора архитектуры в зависимости от задачи. И что не всегда из большего числа параметров следуют лучшие метрики.

Ноутбук:
https://colab.research.google.com/drive/1Q1ENzluOom-CWV_ufXmO3c0Pl6msrK7t?usp=sharing